

# Tech Challenge - Fase 1

Sistema de Apoio ao Diagnóstico de Câncer de Mama

Pedro Bonacelli

Agosto de 2026

## 1. Entregáveis

Link do repositório Git: <https://github.com/PedroBonacelli/feature-fase-1>

O repositório contém: código-fonte completo (src/), README.md com instruções de execução, Dockerfile, instruções de obtenção do dataset (data/raw/README.md), todos os resultados (reports/figures/) e este relatório técnico completo (reports/RELATORIO\_TECNICO.md).

**Vídeo de demonstração:** [link a ser adicionado após a gravação — ver reports/03\_cnn\_extra.md e README para o estado atual do projeto]

## 2. O Problema e o Dataset


Uma rede de hospitais e centros de saúde especializados no atendimento à mulher busca implementar um sistema inteligente de suporte ao diagnóstico e detecção de riscos, capaz de ajudar profissionais de saúde na identificação precoce de condições que afetam a segurança e saúde feminina. Nesta Fase 1, o desafio é construir a base desse sistema com foco em Machine Learning sobre dados médicos estruturados.

**Dataset utilizado:** Breast Cancer Wisconsin (Diagnostic) — 569 exames, 30 features numéricas derivadas de imagens digitalizadas de biópsias por agulha fina (FNA), organizadas em três grupos (mean, error, worst) para 10 medidas de forma/textura do núcleo celular. Fonte: [kaggle.com/datasets/uciml/breast-cancer-wisconsin-data](https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data) (carregado via sklearn.datasets.load\_breast\_cancer, mesma base, origem UCI Machine Learning Repository).

Variável alvo: target (0 = maligno, 1 = benigno). Distribuição: **357 benignos (62,7%) / 212 malignos (37,3%)**.


## 3. Análise Exploratória de Dados (EDA)

O dataset está limpo: **zero valores ausentes, zero duplicatas**. Há separação visual clara entre malignos e benignos em features de tamanho e irregularidade de contorno, coerente com o conhecimento clínico sobre morfologia tumoral.




Distribuição da variável alvo

Distribuição das principais features por diagnóstico



Distribuição das principais features por diagnóstico — nota-se maior separação de classes em radius, perimeter, area, compactness, concavity e concave points

Há forte multicolinearidade entre medidas de tamanho (radius, perimeter, area — correlação  $> 0,98$  entre pares), o que é esperado matematicamente e orientou decisões de modelagem.



Matriz de correlação entre as 30 features

## 4. Pré-processamento

1. Limpeza defensiva (duplicatas, imputação por mediana, descarte de medidas fisicamente inválidas) — 0 registros afetados neste dataset.
2. Separação treino/teste estratificada (80/20  $\rightarrow$  455/114 amostras), preservando a proporção de  $\sim 37\%$  de malignos.

3. Escalonamento (StandardScaler) ajustado somente no treino, evitando vazamento de dados.
4. Análise de correlação confirmou 15 pares de features com correlação > 0,95 — decisão de manter todas as features, contando com regularização e robustez dos modelos à multicolinearidade.

## 5. Modelagem

Três técnicas de classificação foram treinadas e comparadas:

| Modelo                          | Justificativa                                |
|---------------------------------|----------------------------------------------|
| Regressão Logística             | Baseline linear, altamente interpretável     |
| Árvore de Decisão (max_depth=5) | Não-linear, fácil de visualizar/explicar     |
| Random Forest (300 árvores)     | Ensemble mais robusto, comparação mais forte |


**Métrica de avaliação escolhida:** recall e F1 da classe **maligno**, não apenas accuracy — em um dataset com desbalanceamento moderado (63%/37%), um modelo que sempre previsse “benigno” já teria ~63% de acurácia sem detectar nenhum câncer. Um falso negativo (câncer classificado como benigno) é o erro mais grave clinicamente.

## 6. Resultados


Métricas no conjunto de **teste** (114 amostras nunca vistas no treino):

| Modelo              | Accuracy | Precision (maligno) | Recall (maligno) | F1 (maligno) | ROC AUC | Falsos negativos |
|---------------------|----------|---------------------|------------------|--------------|---------|------------------|
| Regressão Logística | 0,983    | 0,976               | 0,976            | 0,976        | 0,995   | 1                |
| Árvore de Decisão   | 0,921    | 0,867               | 0,929            | 0,897        | 0,916   | 3                |
| Random Forest       | 0,947    | 0,929               | 0,929            | 0,929        | 0,994   | 3                |

A **Regressão Logística** obteve o melhor resultado — maior recall e F1 na classe maligno, maior AUC, e apenas 1 falso negativo. O Random Forest teve 100% de acurácia no treino mas ficou atrás no teste, indício de leve overfitting.




Matrizes de confusão dos três modelos no conjunto de teste



Curvas ROC dos três modelos

## Explicabilidade

Três camadas de interpretação foram aplicadas: feature importance nativa, permutation importance (model-agnostic) e uma explicação tipo-SHAP para a Regressão Logística (fórmula analítica exata do SHAP para modelos lineares —  $\phi_i = \text{coef}_i \cdot (x_i - \text{média\_treino}_i)$  — implementada manualmente, pois o pacote shap não pôde ser instalado no ambiente sandbox usado para este desenvolvimento).



Feature importance / coeficientes dos três modelos

As três abordagens convergem: as features mais relevantes são consistentemente **tamanho** (worst radius, worst area, worst perimeter) e **irregularidade de contorno** (worst concave points, concavity) — convergência que reforça que o modelo aprendeu um padrão clinicamente plausível.

## 7. [Extra] Visão Computacional (CNN)

Um pipeline completo de CNN para diagnóstico via mamografia (dataset CBIS-DDSM), incluindo Grad-CAM para explicabilidade visual, foi **desenvolvido e documentado** (`src/cnn_mammography.py`), mas não executado nesta entrega: o ambiente de desenvolvimento sandbox não tem acesso à internet para baixar o dataset (dezenas de GB, requer autenticação Kaggle) nem permite instalar TensorFlow. Código, arquitetura e instruções completas de execução (Colab/local com GPU) documentados em `reports/03_cnn_extra.md`.

## 8. Discussão Crítica: Esse Modelo Pode Ser Usado na Prática?

**Sim, mas apenas como ferramenta de apoio à decisão — nunca como substituto do diagnóstico médico.**

1. **O médico sempre tem a palavra final.** Mesmo com 97,6% de recall, o modelo ainda erra. Em produção, funcionaria como camada de triagem/priorização, nunca liberando um caso como “benigno” sem revisão humana.
2. **Dataset pequeno e de fonte única** (569 casos, um único processo/equipamento de coleta). Validação em dados de outras clínicas/equipamentos seria pré-requisito para uso clínico real.
3. **Explicabilidade é pré-requisito, não luxo**, em saúde — as camadas de interpretação usadas permitem que o profissional julgue se a predição faz sentido clinicamente.
4. **Custo assimétrico dos erros** deveria orientar o ajuste do limiar de decisão em produção.
5. **Próximos passos para uso real:** validação clínica prospectiva, auditoria de viés populacional, monitoramento contínuo pós-deploy, e um fluxo de trabalho onde a predição é sempre uma entre várias informações consideradas pelo médico.

## 9. Conclusão

A Regressão Logística treinada sobre o Breast Cancer Wisconsin atingiu 97,6% de recall e AUC de 0,995 na classe maligno, com pipeline de pré-processamento, análise de correlação e três camadas de explicabilidade documentadas end-to-end. O resultado valida a viabilidade técnica de um sistema de apoio à triagem para essa tarefa, respeitando desde já o princípio de que a decisão final é sempre do profissional de saúde.